

MINERIA DE DATOS

INTEGRANTES:

CAMILA PAVA ID: 909588

NATALIA VALENCIA ID:905559

UNIVERSIDAD MINUTO DE DIOS-RECTORÍA TOLIMA HUILA

ELECTIVA CPC NRC: 95402

ESTEBAN ERNESTO MORALES CASTRO

13 DE SEPTIEMBRE DEL 2026

1. Problema planteado

La información relacionada con vehículos registrados, vehículos hurtados y vehículos recuperados se encuentra distribuida en diferentes fuentes de datos. Cada fuente utiliza sus propias columnas, formatos y formas de representar municipios, departamentos y tipos de vehículo. Esto dificulta realizar un análisis conjunto si los datos no se preparan y normalizan previamente.

El objetivo del proceso fue construir un único dataset que permitiera relacionar, para cada año, municipio y tipo de vehículo, tres indicadores: vehículos registrados, vehículos hurtados y vehículos recuperados.

Pregunta de análisis

¿Cómo integrar información de diferentes fuentes públicas para analizar los vehículos registrados, hurtados y recuperados por año, municipio y tipo de vehículo, manteniendo una estructura consistente y verificable?

2. Fuentes de datos utilizadas

Fuente	Información principal	Uso en la integración
Crecimiento del Parque Automotor RUNT 2.0	Vehículos registrados por ubicación, fecha y clase de vehículo.	Aporta VEHICULOS_REGISTRADOS y sirve para relacionar el parque automotor con la ubicación.
Hurto a Vehículos	Registros/cantidades de vehículos hurtados, fecha, departamento, municipio y código municipal.	Aporta VEHICULOS_HURTADOS.
Recuperación Vehículos Policía Nacional	Vehículos recuperados, fecha, departamento, municipio, código DANE y clase del bien.	Aporta VEHICULOS_RECUPERADOS y facilita la correspondencia geográfica.
municipios_dane.xlsx	Maestro de códigos y nombres oficiales de municipios	Codigos Dane

Después de la limpieza, los volúmenes reportados por el programa fueron: RUNT: 182.978 registros; Hurto: 386.071 registros; Recuperación: 213.668 registros.

3. Clave utilizada para relacionar los datos

La integración se realizó utilizando una clave analítica compuesta por tres elementos:

- AÑO
- CODIGO_DANE_MUNICIPIO
- TIPO_VEHICULO

La selección de estas variables se justifica porque representan dimensiones comunes entre las fuentes y permiten comparar las cantidades sin unir registros de manera arbitraria. El año permite conservar la dimensión temporal, el código DANE permite identificar el municipio y el tipo de vehículo permite comparar categorías equivalentes.

4. Cambios de limpieza y normalización realizados

Normalización de texto

Los nombres de departamentos y municipios fueron normalizados antes de realizar las correspondencias. Se eliminaron espacios innecesarios y se aplicó una normalización común del texto mediante la función `normalizar_texto`.

Justificación: dos fuentes pueden representar el mismo lugar con diferencias de mayúsculas, espacios, tildes u otros caracteres. Si se comparan directamente esos textos, un mismo municipio puede parecer diferente y no coincidir durante la unión.

Normalización de códigos DANE

Los códigos DANE fueron tratados como texto, se eliminaron espacios y se ajustaron a cinco dígitos mediante `zfill(5)`. Posteriormente se verificó que tuvieran exactamente cinco dígitos.

Resultado de la validación final: 54.491 códigos cumplen el formato de cinco dígitos y no se encontraron códigos de cuatro dígitos ni códigos con otra longitud.

Justificación: el código DANE funciona como identificador geográfico. Mantenerlo como texto evita problemas de formato, especialmente cuando un código puede necesitar ceros a la izquierda, y permite que las fuentes utilicen exactamente la misma estructura para la integración.

Normalización del año

En RUNT, el año se obtuvo a partir de la columna `FECHA DE REGISTRO`. En Hurto y Recuperación se obtuvo a partir de `FECHA HECHO`. El resultado se almacenó en la columna `AÑO` para que las tres fuentes tuvieran una dimensión temporal común.

Justificación: las fechas originales no necesariamente tienen la misma estructura, pero para el análisis propuesto se necesita comparar los datos por año. Por eso se extrae una misma variable temporal.

Normalización del tipo de vehículo

Las fuentes no utilizan exactamente los mismos nombres o clasificaciones de vehículos. Por esta razón se creó una clasificación común mediante `ClasificadorVehiculos`.

El resultado final utiliza únicamente dos categorías: `AUTOMOTOR` y `MOTOCICLETA`.

Resultado: `AUTOMOTOR` = 28.358 filas; `MOTOCICLETA` = 26.133 filas.

Justificación: sin una clasificación común no sería posible comparar directamente las cantidades de las tres fuentes. La normalización reduce las diferencias entre las categorías originales y crea una variable `TIPO_VEHICULO` común para la integración.

Normalización de la ubicación del RUNT

El RUNT identifica la ubicación principalmente mediante `NOMBRE_DEPARTAMENTO` y `NOMBRE_MUNICIPIO`. Para integrarlo con las otras fuentes se construyó un mapa de correspondencia entre `CODIGO_DANE_MUNICIPIO`, `DEPARTAMENTO` y `MUNICIPIO`.

Después se realizó una unión entre RUNT y esta tabla de correspondencia usando los nombres normalizados de departamento y municipio. De esta forma se incorporó el código DANE al RUNT.

Justificación: los tres datasets necesitan una referencia geográfica común. Utilizar el código DANE es más adecuado para la integración que depender únicamente del nombre del municipio.

5. Tratamiento de datos ambiguos

Durante la construcción de la correspondencia geográfica se encontraron 81 códigos DANE que aparecían asociados a dos combinaciones diferentes de departamento y municipio.

Estos casos se consideraron ambiguos porque el programa no puede determinar de forma segura cuál correspondencia debe conservarse solamente observando los registros. Algunos pueden corresponder a diferencias de nomenclatura y otros presentan conflictos geográficos.

Decisión tomada: no se eliminaron ni seleccionaron arbitrariamente los registros ambiguos. Se identificaron como una observación de calidad para una validación posterior con una fuente geográfica oficial.

Esta decisión es importante porque eliminar un registro o escoger el primero encontrado podría introducir un error geográfico en el dataset final.

6. Agregación antes de la integración

Después de normalizar los datos, cada fuente fue agregada por AÑO, CODIGO_DANE_MUNICIPIO y TIPO_VEHICULO. Las cantidades se sumaron para obtener los indicadores de vehículos registrados, hurtados y recuperados.

Esto explica por qué el dataset final tiene 54.491 filas, aunque las fuentes originales tenían cientos de miles de registros: las filas finales representan combinaciones analíticas, no cada registro original.

7. Tratamiento y validación de valores nulos

En la validación del dataset final se obtuvieron 0 valores nulos en todas las columnas. Las 54.491 filas están completas y no existen filas con algún campo faltante.

En las variables de cantidades pueden aparecer valores 0. Estos ceros no deben interpretarse automáticamente como que el fenómeno nunca ocurrió. Representan una ausencia de registro para esa combinación en la fuente correspondiente después de la integración.

8. Resultado de la integración

Característica	Resultado
Filas finales	54.491
Columnas finales	8
Duplicados exactos	0
Duplicados por clave	0
Valores nulos	0
Filas completas	54.491
Departamentos	33
Municipios	1.008
Tipos de vehículo	2: AUTOMOTOR y MOTOCICLETA
Códigos DANE con 5 dígitos	54.491

Estructura final:

- AÑO
- CODIGO_DANE_MUNICIPIO
- DEPARTAMENTO

- MUNICIPIO
- TIPO_VEHICULO
- VEHICULOS_REGISTRADOS
- VEHICULOS_HURTADOS
- VEHICULOS_RECUPERADOS

9. Justificación de los resultados estadísticos

El análisis descriptivo mostró que los datos tienen una distribución con muchos valores bajos o cero y algunos valores muy altos. Por ejemplo, en VEHICULOS_REGISTRADOS la mediana es 4, mientras que el promedio es 432,55 y el máximo es 84.348. En VEHICULOS_HURTADOS la mediana es 0, el promedio 14,76 y el máximo 6.522. En VEHICULOS_RECUPERADOS la mediana es 0, el promedio 3,89 y el máximo 689.

La diferencia entre media y mediana indica que existen valores altos que elevan el promedio. Esto es coherente con la presencia de municipios o combinaciones con cantidades mucho mayores que la mayoría de los registros.

10. Valores atípicos (IQR)

Variable	Q1	Q3	IQR	Valores atípicos
VEHICULOS_REGISTRADOS	0	92	92	9.729
VEHICULOS_HURTADOS	0	2	2	8.344
VEHICULOS_RECUPERADOS	0	2	2	6.808

Los valores atípicos identificados por IQR no fueron eliminados automáticamente. La razón es que un valor estadísticamente atípico no necesariamente es un error. Puede corresponder a un municipio con una cantidad de vehículos o casos considerablemente mayor. Por lo tanto, se decidió conservarlos y dejarlos para un análisis posterior.

11. Conclusión

El proceso permitió transformar tres fuentes heterogéneas en un dataset integrado con una estructura común. La normalización se concentró en los elementos necesarios para relacionar las fuentes: texto geográfico, códigos DANE, año y tipo de vehículo.

La integración final contiene 54.491 filas y 8 columnas, sin valores nulos ni duplicados, con 33 departamentos, 1.008 municipios y dos categorías de vehículo. Además, todos los códigos DANE cumplen el formato de cinco dígitos.

Sin embargo, el proceso también permitió detectar 81 códigos DANE con ambigüedad geográfica. Estos casos no se eliminaron de manera arbitraria porque requieren validación con una fuente oficial. Por lo tanto, el dataset puede considerarse estructuralmente preparado para análisis posteriores, pero la validación geográfica de esos casos debe completarse antes de realizar conclusiones definitivas sobre su ubicación.

12. Resumen de decisiones de normalización

Cambio	¿Por qué se hizo?	Resultado
Normalización de nombres de departamento y municipio	Evitar diferencias de escritura que impidan las coincidencias.	Nombres comparables entre fuentes.

Código DANE tratado como texto y ajustado a 5 dígitos	Conservar el identificador geográfico con formato uniforme.	54.491 códigos con 5 dígitos.
Extracción de AÑO desde las fechas	Crear una dimensión temporal común.	Una columna AÑO común para la integración.
Clasificación común del tipo de vehículo	Las fuentes tienen clasificaciones diferentes.	AUTOMOTOR y MOTOCICLETA.
Mapa de correspondencia geográfica	Agregar el código DANE al RUNT a partir de departamento y municipio.	Permite usar una clave geográfica común.
Agregación por año + DANE + tipo	Evitar unir registros sin relación y obtener cantidades comparables.	54.491 combinaciones finales.
No eliminar automáticamente valores atípicos	Un outlier puede ser un dato real y no un error.	Se conservan para análisis posterior.
No resolver arbitrariamente los 81 códigos ambiguos	Evitar introducir errores geográficos sin evidencia.	Quedan identificados para validación oficial.

Archivo generado a partir de los resultados actuales del proceso de minería de datos.